DANIELA PINO CRIADO

Ej7: Analiza los datos e incluye una reflexión de como podrías tener en cuenta la información del experto en los datos que puedes obtener de yahoo finance. (Investiga que datos tiene la API de yahoo u otras interesantes). Justifícalo.

Análisis de los datos recopilados:

La tabla del Ibex tiene 18865 filas tras realizar el merge. De esos, 539 filas son días cotizados de BBVA (descargados en el ejercicio 1), por lo que si dividimos las 18865 entre esos 539 salen exactamente 35 tickers.

Es un dataset equilibrado, 35 tickers y suponemos que 539 días cada uno de ellos. Con esta información se pueden comparar tickers y analizar correlaciones entre ellos.

Con las salidas de mis ejercicios tampoco puedo hacer un gran análisis de los datos del csv, para eso más adelante con las siguientes capas se extraerá esa información de valor.

Lo que si puedo sacar de los outputs es algo de información de BBVA y ACS. Se observa una fuerte tendencia en las empresas cuyos valores se han impreso (BBVA y ACS), ACS, en poco más de un año sube un 108% y BBVA un 104% en las fechas impresas. Esto fue de 2025 a 2026 por lo que se puede deducir que no hace mucho ha tenido lugar un periodo alcista en el Ibex (al menos en estas empresas).

En cuanto a los datos relacionados con el sentimiento, los 5 valores que obtenemos al imprimir las 5 primeras filas del csv en el ejercicio 2-a, se comprenden en el rango entre 45,81 y 53,62. Estas filas son de octubre de 2026 por lo que habría que comprobar si el csv se solapa en datos del IBEX antes de cruzarlos.

Reflexión de cómo considerar la información del experto en los datos que puedes obtener de yahoo finance:

Según mis investigaciones, yfinance proporciona información prospectiva de analistas como precios objetivo, recomendaciones, cambios de rating, estimaciones de beneficios, evolución… e incluso información sobre el sector de cada empresa o ticker.

Implementando esta librería en la tabla de precios y volúmenes se puede llegar a datos valiosos como potencial de revalorización. La información del experto en yahoo permitiría cruzar el csv de sentimiento (repartido en sectores), con los tickers del Ibex y comparar la opinión de los inversores con la de los expertos.

La bolsa depende mucho del momento político, económico y social, por lo que hay que tener mucho cuidado al cruzar datos objetivos de hoy con precios pasados. Los analistas trabajan con sesgos, así que las estimaciones realizadas con el análisis bursátil —aunque ayuden enormemente a los inversores a escoger el momento de compra o analizar qué empresas son propensas a generar beneficios— no deben ser tratadas como una verdad absoluta, sino como una variable cuyo valor predictivo hay que medir.

He encontrado que existen APIs de analistas como Finnhub o Financial Modeling Prep, que dan una cobertura más estable que yfinance, que no es una API oficial.

Ejemplos de datos de la API de yahoo:

analyst_price_targets: aporta el precio objetivo medio, máximo y mínimo.

upgrades_downgrades: consenso comprar/ mantener/ vender y cambios de rating

earnings_estimate, revenue_estimate: estimaciones de beneficios e ingresos y su evolución

earnings_history: beneficio real frente al estimado

info: sector del ticker, industria, PER, beta

Ej8: Construye la capa silver. Limpia la base de datos sentimiento y guárdalo en data/lake/silver/sentimiento. Los sectores del CSV están en español. Justifica la construcción/modificación de los datos en el pdf. Muestra cuántas filas tiene cada tabla.

Capa silver: sentimiento. La silver se construye a partir de la tabla bronze (data/lake/bronze/sentimiento) y se guarda en data/lake/silver/sentimiento en formato Delta.

Se aplican tres transformaciones: primero, eliminación de nulos (dropna). Se descartan las filas con celdas vacías, que no sirven para análisis ni para cruzar con otras tablas. Luego, la normalización de los sectores (traducir_sectores). Se aplica trim y minúsculas, se traduce al nombre de Yahoo Finance los sectores que estén en español y se pasa a Title Case. Así ENERGY y energy pasan a ser el mismo sector, y los sectores quedan con la misma nomenclatura que el campo sector de Yahoo (por ejemplo Financial Services, Utilities). Esto permite, en gold, unir el sentimiento con cada empresa del IBEX por sector. Se obtienen 12 sectores. Por úlitimo, la eliminación de duplicados (dropDuplicates por Fecha y Sector). La tabla bronze tenía 29.304 filas porque en el ejercicio 2c el append duplicó el CSV (14.652 × 2). Al quedarnos con una fila por Fecha y Sector, la silver queda con 14.652 filas, el contenido del CSV original sin repeticiones. Como el resultado coincide exactamente con el original, no había fechas repetidas con valores distintos.

No se modifica el valor de Sentimiento, solo se limpia su contexto. Se mantiene el sector Crypto, que no es un sector de Yahoo. La silver limpia pero no filtra por criterios de negocio, y no afectará al cruce con el IBEX porque ninguna empresa tendrá ese sector.

Ej11 (opcional): Con un anti-join, muestra (a) los precios que se quedan sin sentimiento y

(b) el sentimiento sin precios. Comenta que sucede y como lo solucionas.

a) Hay 1015 precios sin sentimiento, los casos van del 2026-10-01 al 2026-11-10, en los 11 sectores.

Es un único hueco al final, el CSV de sentimiento termina el 2026-09-30 y el IBEX llega al 2026-11-10. Las 29 filas por sector y ticker corresponden a las 29 sesiones de ese periodo.

Solución -> rellenar con el último sentimiento conocido (rellenar_sentimiento), que lleva los nulos de 1.015 a 0, ya que sentimiento es una señal que cambia despacio y arrastrar el último valor evita huecos en las gráficas, pero inventa sentimiento para octubre y noviembre de 2026.

Por eso en el ejercicio 12 añadí Sentimiento_imputado, para distinguirlos.

b) 9042 sentimientos sin precios. En 7000 y pico filas se debe a que el sentimiento empieza en octubre de 2021 y el IBEX en octubre de 2024. Además, Crypto, que son más de 1000 filas, es el único sector con todo su rango sin precios, porque silver/empresas no tiene ninguna empresa de ese sector: son 35 empresas del IBEX no criptomonedas.

Solución -> me parece que hay que descartarlo y no incluirlo en gold.

Son datos fuera del alcance del dashboard que siguen disponibles en silver.

Ej12 (opcional): Vuelve al estudio realizado en el Ej7 y piensa que datos te gustaría ver en el dashboard (adicionales a los datos tal cual) que se hará en power BI (por ejemplo, la variación de precio respecto al día anterior). Realiza al menos dos operaciones/cálculos y guárdalos en una nueva columna.

Para el dashboard he añadido al hecho cinco columnas calculadas con funciones de ventana por ticker, ordenadas por fecha.

Var_diaria y Var_pct miden la variación del cierre respecto a la sesión anterior, en valor absoluto y en porcentaje, y permiten ver de un vistazo qué valores suben o bajan sin recalcularlo en Power BI.

Media_movil_7 es la media del cierre de las últimas 7 sesiones y suaviza el ruido diario.

Rango_pct es la amplitud del día, (High − Low) / Low, una medida de volatilidad intradía.

Tendencia clasifica cada sesión como alcista o bajista según si el cierre está por encima o por debajo de su media móvil, lo que sirve para colorear gráficos.

Por último, Sentimiento_imputado marca las 1.015 filas cuyo sentimiento se ha arrastrado desde el último valor conocido, para distinguir el dato real del propagado. Las primeras sesiones de cada ticker tienen Var_diaria y Var_pct nulas porque no existe un día anterior.

```
Nulos de sentimiento antes: 1015 -> despues de rellenar: 0
Ej12
Columnas del hecho: ['Ticker', 'FechaKey', 'Open', 'High', 'Low', 'Close', 'Volume', 'Dividends', 'Stock_Splits', 'Sentimiento', 'Var_diaria', 'Var_pct'
mputado', 'Rango_pct', 'Tendencia']
Filas con sentimiento imputado: 1015
+-------+--------+-----------------+-------------------+-------------------+-----------------+---------+---------+-----------+-------------------+
|Ticker |FechaKey|Close            |Var_diaria         |Var_pct            |Media_movil_7    |Rango_pct|Tendencia|Sentimiento|Sentimiento_imputado|
+-------+--------+-----------------+-------------------+-------------------+-----------------+---------+---------+-----------+-------------------+
|ANA.MC |20261110|217.0            |-4.8000030517578125|-2.1641131585727322|214.77142769949776|3.98     |Alcista  |26.73      |true               |
|CABK.MC|20261110|12.515000343322754|0.40000057220458984|3.3016969026956193 |11.855714253016881|3.02     |Alcista  |42.92      |true               |
|ANE.MC |20261110|22.079999923706055|-0.39999961853027344|-1.7793577699089274|21.897142682756698|2.99     |Alcista  |36.96      |true               |
|ACX.MC |20261110|15.8100004196167 |0.5100002288818359 |3.3333347877385906 |15.537142753601074|2.99     |Alcista  |58.74      |true               |
|BBVA.MC|20261110|23.6299991607666 |0.3399982452392578 |1.4598464228165078 |22.582857131958008|1.4      |Alcista  |42.92      |true               |
+-------+--------+-----------------+-------------------+-------------------+-----------------+---------+---------+-----------+-------------------+
```

Ej13: Exporta la gold a Parquet en data/export/gold, lista para Power BI. Tras elegir como lo vas a guardar investiga más sobre la forma de estrella para guardar los datos. Justifica en un párrafo.

He decidido guardar la capa gold como esquema en estrella, con una tabla de hechos y dos dimensiones. fact_cotizaciones contiene las claves Ticker y FechaKey y las medidas numéricas, mientras dim_empresa guarda los atributos descriptivos. Esta separación evita redundancias, problemas de tamaño en memoria y permite filtrar por sector o periodo. Ordené el hecho por ticker y fecha para mejorar la interpretación, y usé Parquet ya que al columnar y conservar los tipos, Power BI lee solo las columnas que necesita.

- ¡Declaración del uso de IA!

Durante el desarrollo, usé Claude Sonnet 5.5 como apoyo para revisar el código ante posibles errores y solucionar fallos de ejecución cuando no sabía muy bien cuál era la causa.

Además, realicé diferentes consultas a la IA para pulir el desarrollo de mis funciones delta haciendo mi código lo más eficiente posible. También solicité asesoramiento técnico para entender mejor cómo aplicar conceptos de la teoría como: Parquet, Delta Lake o la arquitectura Medallón.

El uso de esta herramienta se centró en mejorar y validar el modelo una vez estructurado todo, asegurando un gran dominio y una gran comprensión de mi código.